

GreenMart Retail

Informe de Limpieza y Transformación de Datos

Proyecto de Data Engineering · Nexeus Big Data · Junio 2026

1. Estado Inicial del Dataset

El archivo fuente `greenmart_customers_products.csv` fue cargado directamente en Google Colab sin preprocesamiento manual externo. El dataset presentó la siguiente estructura inicial:

Dimensión	Valor
Filas totales	10.400
Columnas	11
Filas duplicadas exactas	367 (3,5%)
Nulos en datos de cliente	722 por columna (6,9%)
Nulos en datos de compra	708 por columna (6,8%)
Tipo de <code>purchase_date</code>	object (texto) — requería conversión

2. Problemas de Calidad Detectados

2.1 Valores faltantes

Los nulos siguieron un patrón estructural claro, no aleatorio. Se identificaron dos grupos independientes:

- 722 registros sin datos de cliente: `customer_name`, `age`, `city` y `purchase_date` presentaron exactamente el mismo conteo de nulos, lo que sugiere transacciones capturadas sin identificación del cliente.
- 708 registros sin datos de compra: `purchase_quantity` y `total_spent` mostraron nulos coincidentes, indicando transacciones sin detalle de monto registrado.

2.2 Filas duplicadas

Se detectaron 367 filas duplicadas exactas (3,5% del dataset), eliminadas antes de cualquier transformación para evitar procesar registros descartables.

2.3 Tipos de datos incorrectos

La columna `purchase_date` estaba almacenada como tipo `object` (texto). Los identificadores `customer_id` y `product_id`, aunque numéricos, requerían conversión a `string` para evitar operaciones aritméticas accidentales.

2.4 Inconsistencias de texto

La columna `product_name` presentó capitalización inconsistente para los mismos productos (por ejemplo: 'Tofu' y 'TOFU', 'Kale' y 'KALE'). Se identificaron 6 casos de duplicados por capitalización que fueron normalizados.

2.5 Valores atípicos

Las estadísticas descriptivas revelaron valores extremos que requirieron análisis: `purchase_quantity` alcanzó un máximo de 199 unidades (mediana: 3), `price_per_unit` llegó a \$499,35 y `total_spent` registró un máximo de \$75.475 con una desviación estándar de \$793 sobre una media de \$57.

3. Acciones de Limpieza Realizadas

Problema	Acción aplicada	Resultado
Duplicados exactos	<code>drop_duplicates()</code>	367 filas eliminadas
<code>purchase_date</code> (texto)	<code>pd.to_datetime(errors='coerce')</code>	Convertida a <code>datetime64</code>
<code>customer_id</code> / <code>product_id</code>	<code>astype(str).str.strip()</code>	Convertidos a <code>string</code> estable
<code>age</code> faltante	Mediana por ciudad; mediana global como fallback	0 nulos restantes
<code>city</code> faltante	<code>fillna('Unknown')</code>	0 nulos restantes
<code>customer_name</code> faltante	<code>fillna('Unknown Customer')</code>	0 nulos restantes
Capitalización inconsistente	<code>str.strip().str.title()</code>	4 columnas normalizadas
<code>total_spent</code> incorrecto	Recalculado con <code>qty × price</code> (tolerancia \$0,02)	0 errores detectados
Outliers numéricos	Método IQR — marcados con flag binario	4 columnas con flag

4. Supuestos y Decisiones Clave

- Los outliers fueron marcados con flag en lugar de eliminados. Valores como `purchase_quantity = 199` o `total_spent = $75.475` podrían representar compras corporativas o mayoristas legítimas. La decisión de retener o eliminar estos registros queda en manos del equipo de negocio.
- Las fechas irrecuperables (`purchase_date` nula) se dejaron como `NaT` conservando el resto del registro. La información del producto y precio sigue siendo válida para análisis de catálogo.

- La fórmula $\text{total_spent} = \text{purchase_quantity} \times \text{price_per_unit}$ fue adoptada como fuente de verdad. Todas las discrepancias superiores a \$0,02 fueron corregidas automáticamente.
- Para age, la imputación por mediana de ciudad reduce el sesgo frente a la mediana global, preservando la distribución demográfica por región.

5. Verificaciones de Validación

5.1 Integridad de total_spent

Se validó la relación $\text{total_spent} = \text{purchase_quantity} \times \text{price_per_unit}$ para todos los registros con datos completos, aplicando una tolerancia de \$0,02 por redondeo de moneda. Resultado: 0 filas con discrepancia. La variable es completamente consistente en el dataset limpio.

5.2 Detección de outliers (método IQR)

Variable	Outliers detectados	Rango válido IQR
age	0	[-9,50 ; 106,50]
purchase_quantity	100	[-3,50 ; 8,50]
price_per_unit	100	[-8,52 ; 29,96]
total_spent	194	[-30,09 ; 80,17]

Los outliers fueron marcados con columnas flag binarias (1 = outlier, 0 = normal) para permitir análisis futuros con o sin estos registros según el caso de uso.

5.3 Verificación del archivo exportado

El CSV limpio fue recargado y validado mediante assert, confirmando que la forma del archivo exportado (10.033 filas × 15 columnas) coincide exactamente con el DataFrame limpio en memoria.

6. Estado Final del Dataset

Métrica	Antes	Después
Filas	10.400	10.033
Columnas	11	15 (+ 4 flags de outliers)
Filas duplicadas	367	0
Nulos en customer_name	722	0
Nulos en age	722	0

Métrica	Antes	Después
Nulos en city	722	0
Nulos en purchase_date	722	700 (fechas irrecuperables, retenidas)
Tipo de purchase_date	object	datetime64[ns]
Errores en total_spent	No verificado	0

7. Entregables

- Notebook de Google Colab con flujo completo: carga, perfilado, limpieza, validación y exportación.
- greenmart_customers_products_clean.csv — dataset limpio con 10.033 registros, 15 columnas y tipos de datos validados.
- Presente informe de limpieza con decisiones, supuestos y resultados de validación.